

Einsatz von Sprachmodellen zu Stance Detection und Sentiment Analysis

Lina Suttrup
1120810

Betreuung:
Prof. Dr. Oswald

Institut für Verteilte Intelligente Systeme
Universität der Bundeswehr München
Fakultät für Elektrotechnik und Technische Informatik

Inhaltsverzeichnis

1	Einleitung	8
1.1	Natural Language Processing	8
1.2	Sentiment Analysis	9
1.3	Stance detection	9
1.4	Zielsetzung und Vorgehen	10
2	Sprachmodelle	11
2.1	Problemstellung	11
2.2	Sprachmodelle auf Basis von LSTMs	12
2.2.1	ELMo	13
2.2.2	ULMFit	14
2.3	Sprachmodelle auf Basis von Transformern	15
2.3.1	GPT	17
2.3.2	BERT	19
2.3.3	RoBERTa	20
2.4	Weitere Sprachmodelle	20
2.4.1	XLNet	20

3	Einsatz von Sprachmodellen	21
3.1	Versuchsaufbau	21
3.2	Die Daten	21
3.2.1	Sentiment140	22
3.3	Sentiment Analysis	23
3.3.1	Ausgangsbasis	23
3.3.2	ELMo	24
3.3.3	BERT	24
3.3.4	GPT	24
3.4	Stance Detection	24
3.4.1	BERT	24
3.4.2	Verwendung anderer Fine Tuning Methoden	24
4	Auswertung	25
4.1	Ergebnisse	25
4.2	Ausblick	25

Bestätigung

Hiermit versichere ich, dass die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt wurden.

Ferner habe ich vom Merkblatt über die Verwendung von Abschlussarbeiten Kenntnis genommen und räume das einfache Nutzungsrecht an meiner Arbeit der Universität der Bundeswehr München ein.

Neubiberg, den 31.08.2020

Lina Suttrup

1. Einleitung

Was wäre, wenn Computer von ihren Erfahrungen lernen könnten, so wie Menschen es tun? Eine Frage, aus der viele Forschungsfelder entsprungen sind. **Künstliche Intelligenz** ist ein großes Themengebiet, aber ohne **Machine Learning** sind Computer nicht „schlauer“ als die Programme, die sie ausführen - und die von Menschen programmiert werden. Zwar kann ein Computer ein Problem mit vorgegebenen Lösungsweg meist weit schneller lösen als der Mensch selber, aber wie kommt er auf diesen Lösungsweg? **Machine Learning** und **Deep Learning** konzentrieren sich auf genau diese Problemstellung.

Seit der Entwicklung erster **Machine Learning** Algorithmen hat dieses Feld immense Fortschritte gemacht, besonders in den letzten Jahren, in denen auch **Deep Learning** durch die Entwicklung immer schnellerer Prozessoren sowie der Möglichkeiten der modernen GPUs zur Parallelisierung von Aufgaben immer weiter in den Vordergrund rücken konnte. Machine Learning und Deep Learning ist heute schon weit verbreitet und wird in den verschiedensten Feldern eingesetzt - von E-Mail Spam Klassifizierung bis hin zur Erkennung von Tumoren auf Röntgenbildern, es bleibt aber weiterhin ein großes Forschungsfeld.

1.1 Natural Language Processing

Ein wichtiger Teil der Künstlichen Intelligenz ist die **Computerlinguistik**, oder auch **Natural Language Processing (NLP)**. Menschliche Sprache ist für Maschinen nur schwer verständlich, da sie im Gegensatz zu Maschinensprachen keiner genauen Logik folgen: Sie ist im Grunde unvorhersehbar und führt selbst bei Menschen zu Missverständnissen. Trotzdem gibt es heutzutage viele Anwendungen von **NLP** im Alltag, und Beispiele wie die heutigen Sprachassistenten zeigen, wie weit dieses Feld in einer sehr kurzen Zeit voranschreiten konnte.

Aufgrund der Komplexität des Problems gibt es meherer Herangehensweisen, um natürliche

Sprache für Maschinen verständlich zu machen. Ihnen allen ist gemein, dass sie Sprache durch Zahlen repräsentieren.

Es gibt Ansätze, die Wörter als einzelne Einheiten nehmen, und diesen einfach eine Zahl zuordnen. Dies hat den Vorteil, dass es leicht umzusetzen ist und auch keine hohe Anzahl an Trainingsdaten braucht. Das Problem daran ist, dass so sehr viel Bedeutung verloren gehen kann - in natürlicher Sprache sind häufig die umgebenden Wörter genauso wichtig wie das betrachtete Wort. Kontext und Wortzusammenhänge gehen durch diesen Ansatz verloren.

Eine weitere bekannte Technik ist der Einsatz von Wortvektoren, die durch ihre hohe Dimensionalität viele Beziehungen zwischen Wörtern bewahren können. Diese Repräsentation ist vielversprechend, aber auch hier kann nicht immer der Kontext gewahrt werden, da einem Wort genau ein Vektor zugeordnet wird.

Eine Verbesserung, nicht nur in diesem Aspekt, bringen **Sprachmodelle**. Sie können vielfältig eingesetzt werden, haben einen großen Wortschatz in verschiedenen Sprachen und sind vortrainiert - sie müssen entsprechend nur der Aufgabe angepasst werden, was einer enormen Zeiterparnis entspricht. Durch Feinabstimmung der verschiedenen Parameter kann bei Sprachmodellen auch viel erreicht werden.

1.2 Sentiment Analysis

Sentiment Analysis ist die Einordnung von Text in Kategorien von Emotionen, wobei es verschiedene Skalen gibt. Die einfachste ist hierbei die Einordnung in „Neutral“, „Positiv“ und „Negativ“, aber es gibt auch Zuordnungen zu Werten von -1 bis 1 oder anderen Zahlenwerten. Diese Werte werden nicht immer mit einheitlicher Bedeutung genutzt.

1.3 Stance detection

Bei **Stance Detection** geht es darum, herauszufinden, wie die Haltung des Autors eines Textes zu einer bestimmten These oder einem allgemeinen Begriff ist. Beste Ergebnisse wurden durch Unterteilung der Aufgabe in zwei Schritte erzielt; Zunächst wird **Topic Modeling** genutzt, um herauszufinden, ob der Text überhaupt mit der Stance in Verbindung gebracht werden kann. Daraufhin wird, falls dies der Fall ist, auf die Stance bezogene **Sentiment Analysis** genutzt, um die Haltung des Autors zu ermitteln.

1.4 Zielsetzung und Vorgehen

Ziel dieser Arbeit ist es, zu erforschen wie gut sich verschiedene **Sprachmodelle** zum Einsatz in Sentiment Analysis und Stance Detection eignen. Dazu werden die verschiedenen Modelle vorgestellt und analysiert, welche für den Einsatz in Frage kommen, da die Modelle durch unterschiedlichen Aufbau oder auch verfügbare Datensätze nicht alle gleich gute Herangehensweisen an die Problemstellung darstellen. Für die Versuche werden mehrere **Corpora** verwendet, von denen die meisten öffentlich zugänglich sind. Alle **Corpora** bestehen nur aus Tweets, die sich aufgrund der limitierten Zeichenlänge und der Popularität der Plattform *Twitter* gut für die Auswertung in beiden Aufgaben eignen. Die Ergebnisse werden ausgewertet und miteinander verglichen.

2. Sprachmodelle

Bis zur Einführung von Sprachmodellen gab es für NLP in Machine Learning ein großes Problem: Textdaten, wie auch Sprache, sind inherent sequentiell. Im Gegensatz zu Bildern, bei denen alle Daten auf einmal verarbeitet werden können, konnte die Textverarbeitung die Beschleunigung durch den Einsatz von GPUs nicht nutzen, da viele Aufgaben nicht parallelisiert werden konnten [2].

Weiterhin gab es keine Möglichkeit, ein schon vortrainiertes Modell für andere Aufgaben weiter zu verwenden, da das Training für die verschiedenen Aufgaben und auch Domänen sehr spezifisch angegangen werden muss. Diese Faktoren führten zu einem deutlichen Mehraufwand von NLP z.B. gegenüber Bildverarbeitung.

Das Ziel von Sprachmodellen ist es, parallele Verarbeitung der Daten möglich zu machen sowie, im Gegensatz zu vortrainierten **Wortvektor Embeddings** wie **GLoVe** den Kontext der einzelnen Wörter im Satz zu wahren. In den Embeddings wird jedem Wort ein Vektor zugewiesen, sodass ähnliche Wörter nah beieinander liegen und die Beziehung zwischen Wörtern erhalten bleibt. Dadurch können interessante Rechnungen aufgestellt werden:

London - England + Spanien = Madrid

Mit ganzen Textsequenzen können aber auch diese Vektor Embeddings aufgrund der fehlenden Kontextinformationen nur bedingt gut umgehen.

2.1 Problemstellung

Wie schon erwähnt muss Sprache sequentiell verarbeitet werden. Dazu werden meist **Gated RNNs** und **Long Short Term Memory (LSTM)** - Netzwerke verwendet [2]. Durch einige

Techniken kann man mit diesen Netzen auch gute Laufzeiten erreichen, aber es besteht ein weiteres Problem: Der Kontext der Wörter geht schnell verloren, da diese Netze einem Wort meist auch nur eine Bedeutung zuordnen können. Der Umstand, dass diese Netze für jede Anwendung spezifisch trainiert werden müssen, macht ihren Einsatz sehr umständlich.

Ein ebenfalls sehr großes Problem in NLP ist die Tatsache, dass **Überwachtes Lernen** mit erheblichem manuellen Aufwand - dem Annotieren und Labeln der Daten - verbunden ist. Es gibt zwar sehr große Mengen an Daten, die durch das Internet verfügbar sind (z.B. alle *Wikipedia-Artikel*, diese eignen sich aber nur für unüberwachte Lernmethoden, da sie nicht gelabelt sind. Die Menge an gelabelten Daten hingegen ist verschwinden gering im Vergleich zu allen frei verfügbaren. Dies legt die Entwicklung eines Systems nahe, das mit **teil-** oder **fernüberwachtem Lernen** auskommt. Heutige Sprachmodelle versuchen hier anzusetzen, indem sie in einem ersten Schritt unüberwacht mit Korpusen unterschiedlicher Größe die Repräsentation einer Sprache lernen, um dann im zweiten Schritt an die zu erfüllende Aufgabe angepasst zu werden. Besonders interessant hierbei sind neueste Entwicklungen [8], durch die ein Modell sogar mit nur einem Beispiel der zu erfüllenden Aufgabe gute Ergebnisse erzielen kann. Dieses Konzept nennt sich **Transfer Learning**, durch Anwendung in der Bildverarbeitung konnten dadurch große Verbesserungen in Zeit und Genauigkeit erreicht werden [1], da ein vortrainiertes Modell nur noch mit Feinabstimmungen für die spätere Aufgabe vorbereitet werden muss.

Das grundsätzliche Ziel von Sprachmodellen ist die Ausgabe des Wortes, das am wahrscheinlichsten auf eine Eingabesequenz folgt. Direkt anwendbar ist dies z.B. auf Textgeneration und Übersetzungen, während für andere Aufgaben leichte Änderungen vorgenommen werden müssen um z.B. für **Sentiment Analysis** eine Zahl zu erhalten, die dem in der Eingabe erkannten Sentiment entspricht. Sieht man diese Zahl als das vorrauszusagende Wort an können diese Änderungen recht leicht umgesetzt werden.

2.2 Sprachmodelle auf Basis von LSTMs

LSTMs können aufgrund ihrer Architektur gut mit kurzen Sätzen umgehen, aber je länger die Wortsequenz, desto schlechter kann sie verarbeitet werden: Es gibt dabei Probleme mit **vanishing** oder **exploding gradients**, je nach Einstellung der Parameter.

Durch die sequentiellen Verarbeitung steigt die Verarbeitungszeit mit der Textlänge an, wodurch **LSTMs** generell langsamer sind als **RNNs**, da die Neuronen komplexer sind.

Trotz dieser Nachteile können mit dieser Architektur für einige Anwendungen geeignete Sprachmodelle erstellt werden.

2.2.1 ELMo

ELMo baut auf der Idee der Wortvektoren oder auch **Word Embeddings** auf. Die von **ELMo** erlernten Wort-Embeddings können in den eigenen, für Aufgaben spezifisch entwickelten Netzen eingebunden werden, um gegenüber sehr festgelegter Vektoren wie **GloVe** Ergebnisse zu erzielen, die zum Zeitpunkt der Entwicklung dieses Modells zu den besten gehörten [3].

Die zweischichtige Architektur besteht aus jeweils einem **Feed-Forward** Netz, dessen Layer in

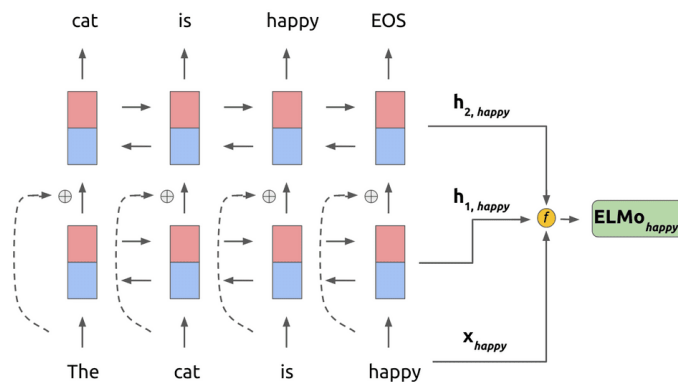


Abbildung 2.1: Aufbau des ELMo-Modells [4]

Abbildung 2.1 in rot eingezeichnet sind und einem **Feed-Backward** Netz, das in blau dargestellt ist. Damit ist **ELMo** ein sogenanntes **bidirektionales Sprachmodell**. Die Schichten bestehen aus jeweils 4096 LSTM-Zellen und zwischen den zwei Schichten gibt es eine Verbindung zur Eingabeschicht. Wie in der Abbildung zu sehen, gibt es demnach drei Repräsentationen für ein Wort, die zusammengenommen das ELMo Embedding ergeben.

Das erste Embedding der Wörter entsteht schon vor dem eigentlichen Sprachmodell, wie Abbil-




Abbildung 2.2: Vorverarbeitung der Wörter [4]

dung 2.2 zeigt. Die Wörter werden in Character-Tokens aufgeteilt und in einem Convolutional Network mit 2048 Filtern und Max Pooling, gefolgt von einem zweischichtigen **Highway Netz** verarbeitet, bevor sie in das LSTM-Netz gegeben werden.

Das Modell wurde mit dem 1B Word Benchmark trainiert, das einen Korpus von 0,8 Milliarden Wörtern besteht und ist damit ein insgesamt sehr großes Modell.

2.2.2 ULMFit

Universal Language Model Fine-Tuning oder auch **ULMFit** ist ein Vorschlag eines von der Architektur recht einfach gehaltenen Sprachmodells, das Transfer Learning in NLP zugänglich machen wollte. Der Ansatz ist besonders darauf fokussiert, ein mit allgemeinen Daten (**Wikitext103**) trainiertes Modell auf eine spezifische Aufgabe mit einem eigenen Kontext (z.B. Medizin, IT etc.) fein abzustimmen [1]. Dadurch wird die Größe des gelabelten Datensatzes und die Anzahl der domänenspezifischen Dokumente, die für ein von Grund auf neu implementiertes Modell benötigt würden stark gemindert.

Das Modell besteht aus drei LSTM-Schichten, die, um Overfitting auf den Daten zu vermeiden, mit einer sehr hohen Dropout-Rate versehen sind. Pro Schicht hat **ULMFit** 1150 versteckte Neuronen.

Bei der Arbeit mit **ULMFit** werden generell drei Schritte ausgeführt [1]:

1. Trainieren des Modells mit einem allgemeinen, großen Datensatz
2. Feinabstimmung des Sprachmodells für die NLP-Aufgabe
3. Feinabstimmung des Klassifikators für die Aufgabe

Schritt 1. muss bei Einsatz des Modells nicht ausgeführt werden, da diese Version des Modells verfügbar ist. Durch diesen Schritt lernt das Modell, in den verschiedenen Schichten die Merkmale der (in diesem Fall englischen) Sprache abzubilden. Bei Schritt 2. wird mit **discriminative Fine-Tuning** und einer abgeschrägten, dreieckigen Lernrate gearbeitet, um Merkmale der in der Aufgabe genutzten Sprache zu lernen. Diese Lernrate wird angewandt, da die verschiedenen Schichten unterschiedliche Merkmale lernen sollen und sich damit die letzten Schichten nicht mehr viel verändern. Schritt 3. nutzt **gradual unfreezing** sowie die beiden in Schritt 2. genutzten Techniken für die Feinabstimmung. Hierfür werden an das Sprachmodell zwei lineare Schichten mit ReLu Activation, dropout und Batchnormalisierung und eine Softmax-Schicht für die Ausgabe.

2.3 Sprachmodelle auf Basis von Transformern

Transformer sind die Basis der heute meistgenutzten Sprachmodelle [5][6]. Sie wurden 2017 entwickelt, um das Problem der sequentiellen Verarbeitung in Maschinellem Übersetzen zu lösen: Als Eingabe kann ein **Transformer** eine ganze Textsequenz verarbeiten. Die wichtigste Komponente in diesem System ist **Attention**: Dadurch kann einem Wort sein Kontext innerhalb der betrachteten Sequenz zugeordnet werden.




Abbildung 2.3: Aufbau eines Transformers [2]

Encoder

Wie in Abbildung 2.3 zu sehen, wird die Eingabe zunächst in Wortvektoren für jedes Eingabewort umgewandelt, die sich aus der Addition des Vektors im **Embedding Space** mit einem **Positionsvektor (Positional Encoding)**, der die Position des Wortes im Satz enthält, ergibt. Der Positionsvektor wird durch Sinus- und Kosinusfunktionen bestimmt. Dieser Eingabevektor wird an einen **Encoder** weitergegeben, der eine **Attention-Matrix** für die Eingabesequenz

erstellt. Sie besteht aus einem Vektor der Länge der Textsequenz für jedes Wort. Diese Matrix enthält Informationen darüber, wie relevant die einzelnen Wörter der Sequenz füreinander sind: In dem Satz

Der braune Hund

bezieht sich z.B. das Wort „Der“ sowie das Adjektiv „braune“ auf das Wort „Hund“. In dem Attention-Vektor wären entsprechend die Werte für „Hund“ in den Vektoren der beiden anderen Wörter höher. **Attention** ist der Schlüsselpunkt für die Funktion der Transformer: Dadurch erhalten die Wortvektoren ihre eigentliche Kontextinformation. Um die Werte zu optimieren werden hier die Mittelwerte von acht Vektoren pro Wort ermittelt.

Alle bisher errechneten Vektoren werden danach aufaddiert, normalisiert und jeder Vektor wird in ein Feed-Forward-Netz gegeben. Hierbei kann parallelisiert werden, da die einzelnen Vektoren voneinander unabhängig sind. Die Ausgabe des **Encoders** sind die mit Kontext und Attention encodierten Wortvektoren.

Decoder

Der **Decoder** ist ähnlich aufgebaut. Er nimmt einen zweiten Input an - der eigentliche Output bei Supervised Learning - der, wie Abbildung 2.3 zeigt, zunächst auch in einen Eingabevektor mit Positionsinformation und Attention-Matrix umgewandelt wird. Im nächsten Schritt werden Input und Output gemeinsam in ein weiteres Netz zur Attention-Bestimmung gegeben, in dem die Attention Matrix der beiden Vektoren zueinander bestimmt wird: Die Frage die hierbei beantwortet wird ist, wie welche Wörter in den beiden Sequenzen zueinander stehen. Dies ist gut an dem Beispiel der Sprachübersetzung zu sehen, bei der der zu lernende Output der Input in einer anderen Sprache ist.

The brown dog

wäre entsprechend hier der Output (Decoder Input). Es wird in diesem Schritt analysiert, wie das Wort „The“ zu „Der“, sowie „braune“ zu „brown“ und „Hund“ zu „dog“ steht. Diese Vektoren werden wieder aufaddiert, normiert und in ein Feed-Forward-Netz gegeben, um noch einmal addiert und normiert zu werden.

Danach wird noch eine lineare und eine Softmax-Schicht angewandt, um am Ende in diesem Beispiel das Wort zu erhalten, dass mit der höchsten Wahrscheinlichkeit als nächstes in dem Output-Satz steht. In der Lernphase wird hierzu **Masking** genutzt, bei dem je ein Wort in dem zu lernenden Output-Satz „maskiert“, also als leerer Platzhalter markiert wird.

2.3.1 GPT

OpenAI hat mit **Generative Pretraining** für Sprachmodelle bis zum Zeitpunkt dieser Arbeit drei Hauptversionen von **GPT** veröffentlicht [6][7][8]. Die Sprachmodelle nutzen den **Decoder**-Teil des Transformers, um ein **autoregressives** System zu erzeugen: Wie in Sprachmodellen üblich wird das jeweils wahrscheinlichste nächste Wort ausgegeben und danach der entstehende Satz weiter als Input genutzt, wie in Abbildung 2.4 zu sehen ist.

Das ursprüngliche **GPT**-Modell besteht aus 12 solcher Decoder-Blöcke, die hintereinander




Abbildung 2.4: Konzept eines autoregressiven Modells

durchgegangen werden. Die folgenden Modelle bieten auch jeweils eine Version mit 12 Decodern, dies ist aber immer die kleinste Version. Die größte Version von **GPT-2** umschließt 48 Decoder-Schichten, während **GPT-3** bis 96 Schichten hat. Das momentan größte GPT-Modell hat somit mit Decoder-Parametern und eigenen Parametern für Positional Encoding und Embedding 175 Milliarden Parameter, ein großer Schritt nach den 1,5 Milliarden von **GPT-2**.

Der weitere Unterschied dieser Modelle sind die genutzten Trainingsdaten: Das erste Modell wurde mit verschiedenen Datensets trainiert, die zusammen eine Größe von knapp über 15GB erreichen, darunter die 1B Word Benchmark und PG-19. Für **GPT-2** wurden ca. 40GB Daten genutzt, enthalten in dem Datensatz **WebText**, der für diese Aufgabe erstellt wurde. Die für **GPT-3** verwendeten Daten hingegen umfassen über 500GB alleine mit dem genutzten Teil des

CommonCrawl Datensatzes, der Texte aus dem Internet von 2016 bis 2019 enthält und auf Duplikate überprüft wurde. Weiterhin wurden das eigene **WebText2** und die Datensätze **Books1**, **Books2** und das englischsprachige Wikipedia. Die Batchsize dieses Modells ist 0,5 Millionen. Das Modell übertrifft damit an Größe bei Weitem das, was bis zu seiner Veröffentlichung vorhanden war. Es ist ein Meilenstein für teilüberwachtes und auch unüberwachtes Lernen: **GPT-3** kann Aufgaben teilweise im Ansatz lösen, ohne Beispiele gesehen zu haben oder auch für diese Aufgabe gelernt zu haben. Besser funktioniert aber die **Few-Shot**-Technik: Man zeigt dem Modell eine gewisse Anzahl (unterer zweistelliger Bereich oder weniger) an Beispielen der Aufgabe, die gelöst werden soll und fragt danach ab. Dies ist aufgrund der wenig vorhandenen gelabelten Datensätze ein großer Vorteil dieses Modells.

GPT arbeitet als Input mit sogenannten **Kontexten**: Dazu gehören hier die Beschreibung der zu erfüllenden Aufgabe, eventuelle Beispiele und der **Prompt**, der dazu auffordert, die Aufgabe mit dem Prompt als Input zu lösen. Ein Beispiel für einen Kontext ist [8]:

```
A "whatpu" is a small, furry animal native to Tanzania.  
An example of a sentence that uses the word whatpu is:  
We were traveling in Africa and we saw these very cute whatpus.  
To do a "farduddle" means to jump up and down really fast.  
An example of a sentence that uses the word farduddle is:
```

Diese Aufgaben und Sätze sind von Menschen geschrieben als Input an das **GPT**-Modell gegeben worden. Die in Anführungszeichen stehenden Wörter sind frei erfunden, um zu zeigen, wie das Sprachmodell mit neuen Wörtern umgeht. Der von **GPT** generierte Output ist:

```
One day when I was playing tag with my little sister, she got  
really excited and she started doing these crazy farduddles.
```

Viel Feinabstimmung braucht **GPT-3** damit nicht mehr, was einer enormen Zeitersparnis entspricht. Die Vorgängermodelle sowie auch **GPT-3** für bessere Ergebnisse sollten jedoch mit einem überwachten Trainingsschritt fein abgestimmt werden.

Wichtig zu beachten ist, dass diese Modelle aufgrund der Qualität der generierten Texte, die größtenteils nicht mehr von von Menschen geschriebenen zu unterscheiden sind, auch gewisse Risiken bergen [8]: Es ist deutlich einfacher, damit Fake News und Fehlinformationen zu generieren und zu verbreiten.

2.3.2 BERT

Wie auch **GPT** basiert **BERT** auf der Idee, einen Teil des **Transformers** zu gebrauchen, um ein Sprachmodell zu erstellen. Hier wird jedoch nicht der **Decoder**, sondern der **Encoder** genutzt: Es gibt zwei Versionen von **BERT**, die kleinere (**BERT Base**) besteht aus 12 Encoder-Schichten - genannt **Transformer-Blöcke**, während **BERT Large** 24 Blöcke (und damit 340 Millionen Parameter) umfasst [5]. Zur Zeit seiner Veröffentlichung stellte **BERT** für viele Aufgaben in NLP die state-of-the art Ergebnisse.

Schon am Namen dieses Sprachmodells kann man erkennen, das es nach dem Modell von **ELMo** kommen soll: Die von **GPT** nicht genutzte, aber in **ELMo** sehr erfolgreich angewandte Bidirektionalität sollte wieder eingeführt werden. Dies hat den Hintergrund, dass in Sprache nicht nur die Wörter wichtig für den Kontext eines bestimmten Wortes sind, die im Satz davor stehen - vielmehr ist die ganze Sequenz wichtig, um den ganzen Kontext zu erfassen. Ein reines Feed-Forward-Netz ist dazu nicht in der Lage. Die **Transformer**-Architektur bietet aufgrund der **Self-Attention**-Schichten eine gewisse Möglichkeit für bidirektionalen Kontext. Um dies auszunutzen, wird **BERT** mit verschiedenen Datensätzen und zu einem gewissen Grad randomisiert vortrainiert. Zu diesem Vortraining gibt es zwei Komponenten, die in einem Schritt ausgeführt werden. **BERT** erhält dazu als Input zwei Sätze. Das **Masked Language Model** wird mit jedem der beiden Sätze trainiert, in denen zufällig Wörter maskiert werden, was effektiv einem Lückentext entspricht. **BERT** muss nun lernen, die in dem Satz fehlenden Wörter einzusetzen. Die ausgegebenen Wortvektoren der maskierten Wörter werden mit einer Output-Schicht mit dem Vokabular entsprechender Anzahl an Neuronen (hier 30000, das Vokabular von **WordPieces**) mit Softmax in eine Wahrscheinlichkeitsverteilung umgewandelt und mit einer one-hot codierten Version des tatsächlichen Wortes abgeglichen. Auch möglich ist, dass statt der Maskierung ein Wort durch ein nicht in den Satz passendes ersetzt wird und das Modell diesen Fehler korrigieren soll. Ebenso wird **Next Sentence Prediction** umgesetzt, bei der das Modell ausgibt, ob die beiden als Input gegebenen Sätze korrelieren.

Für die Feinabstimmung des Sprachmodells werden die Parameter der Output-Schicht durch einen aufgabenspezifischen Datensatz neu erlernt.

Als Input verarbeitet **BERT** Sequenzen, wobei hier spezielle Tokens genutzt werden. Zu Beginn einer Sequenz wird das Token [CLS] gesetzt, das als Platzhalter für den Klassifikator fungiert. Der Klassifikator wird nach Verarbeitung durch **BERT** mit einem aus einer einzigen Schicht bestehenden Feed-Forward-Netz mit Softmax bestimmt. Soll mehr als ein Label ausgegeben werden muss hier die Anzahl an Output-Neuronen angepasst werden. Für die anderen Wörter der Sequenz werden die erstellten Wortvektoren ausgegeben, bei **BERT Base** haben diese 768

Dimensionen.

Das Token [SEP] wird gebraucht, um zwei zusammenhängende Sequenzen zu trennen, z.B. bei Frage/Antwort-Paaren. Hierbei wird dann an der Position des [CLS]-Tokens kein Klassifikator mehr ausgegeben, sondern die Wahrscheinlichkeit, dass der Satz nach [SEP] auf den Satz vor dem Token folgt.

So kann **BERT** für die verschiedensten Aufgaben verwendet werden. Aber auch die reinen Word Embeddings können ausgelesen und in einem eigenen erstellten Netz für weitere Aufgaben verwendet werden. Da jeder Decoder-Block des Modells einen eigenen Vektor für jedes Wort ausgeben kann, muss man im Einsatz dabei jedoch darauf achten, welche dieser Schichten die am besten Kontextualisierung des Wortes darstellt. In Tests der Entwickler erreichte hierbei eine Verkettung der letzten vier Schichten die besten Ergebnisse [5].

2.3.3 RoBERTa

2.4 Weitere Sprachmodelle

2.4.1 XLNet

3. Einsatz von Sprachmodellen

Im Zuge dieser Arbeit wurden Versuche mit verschiedenen Sprachmodellen durchgeführt, die im Folgenden beschrieben werden.

3.1 Versuchsaufbau

Der Source Code für die Versuche ist in Python verfasst, da die Sprachmodelle alle eine übersichtliche Schnittstelle zur Verwendung in Python bieten. Die erstellten Netze sind durch die Bibliotheken *keras* [12] und *Tensorflow* [13] implementiert worden.

Der Code wurde zum Testen auf Googles Plattform *Google Colab* [14] ausgeführt, da mit dieser Plattform eine Laufzeitumgebung mit Möglichkeit zur Nutzung von einer GPU sowie - falls nötig - einer TPU zur Verfügung steht. Die genutzten Datensätze werden über Links zu der Datenquelle (*kaggle.com*, *github.com*) eingebunden.

3.2 Die Daten

Für **Sentiment Analysis** werden ausschließlich Daten genutzt, die von der Plattform *Twitter* genommen wurden. Diese Daten eignen sich sehr gut für diese Aufgabe, da die Länge der Textstücke auf 280 Zeichen begrenzt ist [10] und es eine große Nutzerbasis und damit eine große Vielfalt an formulierten Texten gibt. Hierbei werden die Tweets genommen, die nur Text und entsprechende Emojis enthalten und in Englisch verfasst sind. Einige der genutzten Datensätze sind gelabelt, um damit **Supervised Learning** zu betreiben, andere sind zum Test der entstehenden Netze und nicht gelabelt.

Die Daten werden alle vorverarbeitet, um die Texte einheitlich und gut verarbeitbar zu machen. Hierzu werden für die Tweets folgende Schritte durchgegangen:

- alle Wörter in Kleinbuchstaben umwandeln
- doppelte Buchstaben entfernen
- Whitespaces an Anfang und Ende entfernen

Weiterhin werden die Tweets einer **Tokenization** unterzogen, durch die die Wörter, Emojis und Links in **Tokens** umgewandelt werden. Hierbei wird auch **Stemming** angewendet: Dadurch werden die Wörter in ihre Grundform umgewandelt mit vorausgehenden oder nachfolgenden Silben als separate Tokens. Aus dem Wort „playing“ werden so z.B. die zwei Tokens <play> und <ing>. Diese Art der **Tokenization** ist für den Einsatz mit Sprachmodellen am besten geeignet, da auch in diesen nicht alle Vokabeln einer Sprache enthalten sein können - das wäre schlicht ein zu großes Vokabular. Durch **Stemming** wird gewährleistet, dass die meisten Wörter, sowie die jeweilige Präfix und Suffix je einem Vektor zugeordnet werden können (sollten keine Rechtschreibfehler enthalten sein).

Die Daten für den Teil **Stance detection** haben unterschiedliche Ursprünge. Datensätze bestehen hauptsächlich aus Artikeln, deren Überschriften und den jeweiligen angesprochenen Stances. Auch diese Daten werden einer **Tokenization** unterzogen. Diese unterscheidet sich nur leicht von der für die **Sentiment Analysis** durchgeführte, da die Artikel im Allgemeinen keine sogenannten *handles* oder Emojis enthalten. Diese Datensätze sind gelabelt, um einen späteren Test möglich zu machen.

Wie bei sehr vielen Machine Learning Aufgaben hängen die Ergebnisse stark von der Qualität der genutzten Daten ab. Es wurde demnach versucht, alle Datensätze so zu reinigen, dass die Performanz optimal wurde. Auf etwaige zusätzliche Schritte wird in der jeweiligen Beschreibung eingegangen.

3.2.1 Sentiment140

Dieser Datensatz [11] enthält 16 Millionen Tweets, die mit einem Sentiment-Wert von 0 bis 4 annotiert sind, wobei 4 positiv und 0 negativ ist. Da **sentiment140** von seinen Urhebern schon zum Training für Sentiment Analysis genutzt wurde, ist dieser Datensatz schon weitestgehend gesäubert: Er enthält nur noch wenige doppelte Buchstaben und keine Emoticons, was für die

reine Textauswertung hilfreich ist. Somit müssen in diesem Datensatz noch Nutzernamen und Links entfernt oder in Tokens umgewandelt werden.

Es sind weiterhin nur Tweets enthalten, in denen nicht positive und negative Sentiments gleichzeitig ausgedrückt werden. Der Datensatz wurde durch Auswertung von Emoticons erstellt.

3.3 Sentiment Analysis

3.3.1 Ausgangsbasis

Um einen Vergleich zu haben, wie performant und genau **Sentiment Analysis** mit Sprachmodellen ist, wurde zunächst ein Ansatz ausgewertet, der keinen Gebrauch von Deep Learning macht. Die Veränderung der Genauigkeit im Vergleich zu diesem Ansatz gibt einen Anhaltspunkt, wie viel Sprachmodelle in Sentiment Analysis leisten können.

Zur Auswertung wird der Datensatz 3.2.1 genommen, da dieser genügend groß ist, um eine fundierte Aussage zu treffen. Dieser Datensatz wird mit pythons *pandas* Bibliothek eingelesen, gesäubert und im Anschluss mit der Bibliothek *TextBlob* ausgewertet. Diese Auswertung basiert auf manuell erstellten Dokumenten, in denen allen Wörtern Sentiment-Werte zugeordnet wurden. *TextBlob* werten diese Werte für einen gegebenen Text aus und gibt einen Wert zwischen -1 und 1 zurück (negativ zu positiv).

```
filteredData.tweet.map(lambda x: TextBlob(x).sentiment.polarity)
```

Listing 3.1: Auswertung mit TextBlob

3.3.2 ELMo

3.3.3 BERT

3.3.4 GPT

3.4 Stance Detection

3.4.1 BERT

3.4.2 Verwendung anderer Fine Tuning Methoden

4. Auswertung

4.1 Ergebnisse

4.2 Ausblick

Abbildungsverzeichnis

2.1	Aufbau des ELMo-Modells [4]	13
2.2	Vorverarbeitung der Wörter [4]	13
2.3	Aufbau eines Transformers [2]	15
2.4	Konzept eines autoregressiven Modells	17

Literaturverzeichnis

- [1] Howard, J., Ruder, S., Universal Language Model Fine-tuning for Text Classification. 2018, arXiv:1801.06146
- [2] Vaswani, A. et al., Attention Is All You Need. 2017, arXiv:1706.03762v5
- [3] Peters, M., Neumann, M., Iyyer, M., Gardner, M., Clark, C. , Lee, K., Zettlemoyer, L., Deep contextualized word representations. 2018, arXiv:1802.05365v2
- [4] Mihail, E., Deep Contextualized Word Representations with ELMo. 2018, <https://www.mihaileric.com/posts/deep-contextualized-word-representations-elmo/>
- [5] Devlin, J., Chang, M., Lee K. , Toutanova, K., BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2019, arXiv:1810.04805v2
- [6] Radford, A., Narasimhan, K., Salimans, T., and Sutskever, I., Improving language understanding by generative pre-training. 2018, <https://openai.com/blog/language-unsupervised/>
- [7] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., Language Models are Unsupervised Multitask Learners. 2018, <https://openai.com/blog/better-language-models/>
- [8] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D., Language Models are Few-Shot Learners. 2020, arXiv:2005.14165
- [9] Go, A., Bhayani, R., Huang, L., Twitter Sentiment Classification using Distant Supervision. 2009
- [10] So twitterst du. <https://help.twitter.com/de/using-twitter/how-to-tweet>
- [11] <http://help.sentiment140.com/for-students>
- [12] <https://keras.io/>
- [13] <https://www.tensorflow.org/>
- [14] <https://colab.research.google.com/notebooks/intro.ipynb>